面向复杂曲面场景的小参数视觉-语言大模型驱动药品标签端到端识别系统

作者信息待补充

摘要

药品标签的可靠识别是医院静脉用药调配中心（PIVAS）、动物医院及连锁药店等场景中保障用药安全的关键环节。然而，瓶体曲面形变、覆膜反光及标签磨损等复杂成像条件对传统字符识别（OCR）方法构成严峻挑战：在本文构建的含 81 段视频、涵盖 10 类药品的测试集上，Tesseract 因大量帧输出空白（空帧率约 70%）而几乎完全失效；PaddleOCR 虽能在多数帧上提取到局部字符片段（有效输出率 91%），但受曲面投影形变影响，输出呈高度碎片化且存在严重失真，难以在字段层面拼合出可供业务核验的规范化药品名称。为此，本文提出一种基于小参数视觉-语言大模型（VLM）的药品标签端到端识别系统：系统将多角度短视频输入按帧抽取与质量筛选后送入 VLM，由模型完成多模态 OCR 与字段语义解析的一体化推理，并经知识库约束将输出对齐至规范化药品名称，同时输出不确定性等级。实验表明，本文方法在上述测试集上的药品名称**有效识别率**（ERR，即输出可用规范化药品名称的比例）约为 100%，而两种传统 OCR 基线的有效识别率均为 0%（Tesseract 因大量帧空白导致字符级输出亦极度残缺，PaddleOCR 虽 FAR 达 91% 但输出高度碎片化，字段层面均不可用）。平均处理耗时仅 2.10 秒，在有效识别率与处理效率两个维度上均大幅领先两种传统基线方法。所用 Qwen3-VL-8B 参数量仅 8B，可在配备 32 GB 统一内存的消费级处理器（如 AMD AI MAX 系列）上直接本地运行，无需独立 GPU，将边缘部署的硬件成本降至消费级，同时满足实际场景对数据隐私保护与低部署成本的双重需求。

关键词：视觉-语言大模型；复杂曲面 OCR；药品标签识别；知识库约束；多模态推理

1 引言

药品标签信息的准确识别与核对是确保患者/动物用药安全的”最后一道防线”。以静脉用药调配中心（PIVAS）为例，每日需对数百至数千袋次配制药品进行终末校验，核对内容涵盖药品名称、规格、批号、有效期及溶媒剂量等关键字段[16]。类似地，动物医院、连锁药店等场景同样面临药品种类繁多、标签格式复杂的挑战。人工目视核对在高强度重复作业下容易出现疲劳误判，而基于条形码的方案在条码缺失或污损时即失效。因此，构建一套鲁棒、高效且可落地的药品标签自动识别系统具有重要的现实意义。

光学字符识别（OCR）是文本提取的传统技术路线，以 Tesseract[1] 和 PaddleOCR[2] 为代表的工具在印刷体文件和平整标签上表现出良好性能。然而，药品瓶体多为圆柱或异形曲面结构，标签在曲面上的投影产生透视形变；瓶体覆膜与光滑外壳导致高光反射区域出现字符断裂；配液操作与物流搬运造成标签磨损、起皱或污染。上述因素叠加导致传统 OCR 在复杂药瓶场景下性能显著退化，主要表现为：（1）输出字符片段化，无法对齐到完整字段；（2）字符失真严重，错字漏字率高；（3）无法输出置信度或不确定性估计，难以判断何时需要人工介入。

近年来，视觉-语言大模型（Vision-Language Model, VLM）在场景文字理解[9]、文档智能问答 [6] 等任务上展现出超越传统 OCR 流水线的能力。其核心优势在于：跨模态语义理解使模型能够在字符不完全可见时借助上下文完成字段级解析；端到端输出结构化信息，无需额外拼接模块；以及输出不确定性标记，为系统提供保守决策依据。尽管 Qwen3-VL[7]、Qwen2.5-VL[6]、InternVL3[8] 等新一代 VLM 已推出 8B 以下的小参数版本，模型参数规模与部署成本大幅降低，但如何将其有效应用于药品标签这一具有封闭知识库约束的垂直场景，并在复杂曲面成像条件下实现字段级规范化输出，目前尚缺乏系统研究。

本文针对上述问题，提出一种基于小参数 VLM 的药品标签端到端识别系统，并在包含 10 类真实药品、81 段视频的测试集上与 Tesseract 和 PaddleOCR 进行对比实验。本文的主要贡献如下：

1. **端到端系统验证**：验证了”前端采集平台——中间层通信——后端识别服务”三层架构在复杂曲面药品标签识别场景中的工程可行性，提供了从硬件采集到规范化业务输出的完整闭环实现，具备实际可部署性。

2. **实验评估**：构建涵盖 10 类药品的真实复杂场景测试集，以有效识别率（ERR）和处理耗时为核心指标，系统评估本文方法与传统 OCR 基线的差异，揭示

VLM 在曲面场景下对传统方法的根本性优势；消融实验进一步验证知识库约束对 ERR 的关键贡献。

3. **不确定性量化:**通过提示词工程引导 VLM 输出字段级不确定性等级（低/中/高），为保守决策与人工介入触发提供可靠依据，增强系统在安全关键场景下的可信性。

2 相关工作

2.1 传统 OCR 方法

Tesseract[1] 是目前使用最广泛的开源 OCR 引擎之一，通过多阶段流水线（自适应二值化、连通域分析、字典匹配）实现文本识别。尽管其在标准印刷文档上表现良好，但在曲面形变、光照不均及字体多样等复杂场景下性能显著下降；对中文复杂字形的支持亦依赖专用语言模型，误识率偏高。

PaddleOCR[2] 基于深度学习检测-识别二阶段框架，集成了 DBNet[12] 文本检测与 CRNN[13] 序列识别等先进模块，在多语言场景文字识别基准上取得了较优性能。然而，其输出仍为文本行级别的字符串序列，缺乏字段级语义理解能力，且对曲面投影导致的字符几何形变适应性有限。

更广泛地，以 ASTER[14]、ABINet[15] 为代表的场景文字识别（STR）方法通过注意力机制与语言模型提升不规则文本的识别精度，但仍主要针对单行或短串文本，难以直接处理药品标签这类多行、多字段的复杂版式。

2.2 视觉-语言大模型与文档/场景文字理解

VLM 在 OCR 和文档理解领域正经历快速迭代。在通用多模态理解方向，OpenAI 的 GPT-5.4[3]（2026 年 3 月）将推理、编程与多模态理解融为一体，支持图像输入与百万 token 上下文，是目前性能最强的通用多模态前沿模型之一。阿里巴巴的 Qwen3.5-397B-A17B[4]（2026 年 2 月）采用线性注意力与稀疏 MoE 融合架构，激活参数仅 17B，具备原生视觉-语言能力，在推理、编程与多模态理解基准上均取得领先成绩。Anthropic 的 Claude Opus 4.6[5]（2026 年 2 月）具备强大的图像理解、文档解析与多步视觉推理能力，在视觉理解基准上取得领先成绩，并支持原生 Agent 团队协同。上海人工智能实验室的 InternVL3[8]（arXiv:2504.10479）通过原生多模态预训练与高分辨率视觉编码器，在 OCRBench 等文字识别基准上

取得了 906 分（满分 1000）的领先成绩。

在专用 OCR 方向，GOT-OCR2.0[9] 提出通用光学字符识别框架，以端到端方式统一处理印刷体、手写体及场景文字。DeepSeek 团队发布了专用 OCR 模型 DeepSeek-OCR[10]（arXiv:2510.18234，2025 年 10 月）与 DeepSeek-OCR 2[11]（arXiv:2601.20552，2026 年 1 月），后者引入语义感知的视觉 token 动态重排序机制，标志着面向 OCR 的专用小参数 VLM 成为新的研究热点。

与上述工作不同，本文聚焦于特定垂直场景下的小参数 VLM 应用：不追求通用文字识别的极限性能，而是通过提示词工程与知识库约束，将 VLM 的开放式输出引导为符合业务规范的结构化字段，并在 8B 参数级别实现消费级硬件（32 GB 统一内存）上的本地部署。

2.3 药品与医疗标签识别

医疗场景中的标签识别已有部分研究关注。文献 [17] 提出基于模板匹配的药品包装字段提取方法，但高度依赖预定义模板，泛化能力不足。文献 [18] 将深度学习检测与传统 OCR 结合用于针剂瓶标签识别，在受控光照条件下取得较好效果，但对曲面反光场景的鲁棒性未作评估。总体而言，以 VLM 为核心识别引擎处理复杂曲面药品标签的系统性研究目前仍属空白。

说明：以上引用中标有 [待核实] 的条目需在正式提交前补充完整信息。

3 方法

3.1 系统总体架构

本文提出的系统采用”前端采集平台——中间层通信——后端识别服务”的三层架构（图 1），覆盖从硬件采集到业务输出的完整链路。后端识别服务是本文的核心，其内部流程分为三个阶段：（1）视频预处理与帧质量筛选；（2）小参数 VLM 多模态识别；（3）知识库约束输出对齐。

3.2 视频预处理与帧质量筛选

前端采集平台以固定帧率（$f_s = 5$ 帧/秒）采集药品瓶体视频，经中间层传输至后端后进行如下处理：对每一帧图像执行以下处理：

系统架构图（占位）

待替换为：前端采集平台 → 通信中间层 → 后端识别服务（帧筛选 →VLM 推理 → 知识约束 → 结构化输出）流程图

图 1: 系统总体三层架构。前端采集平台负责视频获取，中间层负责数据传输与任务调度，后端识别服务完成帧筛选、VLM 多模态推理与知识库约束，最终输出规范化药品名称与不确定性等级。

1. **背景裁剪**：基于聚类分析去除图像中占主导面积的背景区域，裁剪并对齐药瓶标签区域，以减少无效像素对 VLM 注意力的干扰。
2. **清晰度评估**：计算图像局部梯度强度（拉普拉斯方差），过滤运动模糊或严重遮挡帧。
3. **多帧聚合**：从有效帧池中选取至多 $N_{\max} = 15$ 帧送入 VLM，以充分利用多角度视觉证据，同时控制推理延迟。

图像在送入 VLM 前统一压缩至最长边不超过 1280 像素，JPEG 质量因子设为 85，以平衡细节保留与传输带宽。上述参数（帧率 5 fps、最大帧数 15、图像分辨率 1280 px、JPEG 质量 85）均经预实验确定，在识别效果与处理延迟之间取得合理平衡，未作进一步超参数搜索。

3.3 基于小参数 VLM 的多模态识别

本文以 Qwen3-VL-8B[7] 作为核心识别引擎。该模型参数量为 80 亿（8B），在同类 VLM 中属轻量级，可借助 AMD AI MAX 系列等边缘推理加速平台实现本地部署，兼顾识别性能与隐私保护需求。

系统将多帧图像与结构化提示词一同输入 VLM，要求模型完成以下一体化推理：（1）从多帧图像中读取可见文字片段（多模态 OCR）；（2）综合多角度证据，将碎片化文字对齐到业务字段（字段级语义解析）；（3）输出不确定性等级（低/中/高），标记识别可靠性。

与传统”先 OCR 后 NLP”的两阶段流水线不同，VLM 将字符识别与字段理解融合为单次前向推理，能够在字符部分不可见的情况下借助上下文（如适应症描述、品牌词汇、化学名）推断缺失字段，显著提升对噪声和遮挡的鲁棒性。

3.4 知识库约束与结构化输出对齐

为将 VLM 的开放式自然语言输出转化为可用于业务校验的规范化结果，本文在提示词中嵌入药品名称知识库（合法输出列表），并明确要求模型从知识库中选择语义最接近的条目作为最终输出。知识库中同时维护别名映射表，处理商品名、通用名、英文名及印刷变体的多对一对应关系（例如，”卫佳® 伍”/”Vanguard Plus 5”等均映射至标准名称）。

当模型输出不确定性等级为”中”或”高”时，系统触发保守决策，将该帧标记为”待人工复核”并记录可见文字片段作为审计证据，从机制上避免”猜测式补全”带来的误判风险。

完整提示词设计包含以下要素：（1）角色定义：药瓶识别助手，仅依据可读文字，不凭外观猜测；（2）多帧综合策略：优先采用清晰度高、出现频次多的字段；（3）输出格式约束：关键信息摘录/药品名称（知识库选取）/不确定性；（4）合法输出列表：10 类标准药品名称；（5）别名映射说明：20 余条品牌/通用名对应关系。

4 实验

4.1 数据集与实验设置

数据集。我们构建了一个包含 81 段视频的真实场景药品标签测试集，涵盖 10 类药品产品（表 1），均为注射用圆柱形玻璃瓶，包括注射用抗生素、生物制品及动物疫苗等多种类别。视频由自研采集平台获取：平台由固定摄像头、补光灯与电机驱动的旋转托架组成，药品瓶体平放于旋转托架上，电机驱动托架带动瓶体匀速旋转，摄像头静止拍摄以获取瓶体完整一周的标签视频。该采集方式能够系统性地覆盖曲面投影形变、标签正反面及侧向光照变化等复杂成像条件，同时在视频中引入了自然出现的覆膜反光与标签磨损等真实难例。

基线方法。选取两种代表性传统 OCR 工具作为基线：（1）**Tesseract**（版本 5.x，语言包：`chi_sim+eng`）；（2）**PaddleOCR**（PP-OCRv3，中英文混合模型）。两

表 1: 测试集药品类别分布。

编号	药品类别	包装形态
1	注射用头孢噻呋钠	圆柱玻璃瓶
2	注射用头孢曲松钠	圆柱玻璃瓶
3	贝伐珠单抗注射液	圆柱玻璃瓶
4	贝倍旺狂犬病灭活疫苗	圆柱玻璃瓶
5	瑞比克狂犬病灭活疫苗	圆柱玻璃瓶
6	卫佳捌犬四联活疫苗	圆柱玻璃瓶
7	犬四联活疫苗（国产）	圆柱玻璃瓶
8	金喵乐猫三联灭活疫苗	圆柱玻璃瓶
9	妙三多猫三联灭活疫苗	圆柱玻璃瓶
10	猫三联灭活疫苗（国产）	圆柱玻璃瓶

者均按官方推荐配置运行，不经额外微调。

评测指标。定义以下两项主要指标：

- **有效识别率（ERR，Effective Recognition Rate）**：系统能够输出正确规范化药品名称的视频占总测试视频的比例。此处”有效”强调字段级可用性：仅当输出内容为知识库中的合法条目且语义正确时，该视频才计入分子。传统 OCR 方法仅能输出碎片化字符串，无法形成可供业务核验的规范化药品名称，故其 ERR 记为 0%。这与”有无字符输出”（即帧有效输出率 FAR）是两个本质不同的度量维度。

- **平均处理耗时（$\bar{t}$）**：处理单段视频（含帧提取、模型推理及输出解析）的平均墙钟时间，计算时排除首次冷启动样本。

此外，补充报告**帧有效输出率（FAR，Frame Active Rate）**，即在所有抽取帧中，OCR/VLM 产生非空字符输出的帧占比，用于刻画各方法在字符级别的原始覆盖能力——FAR 高并不意味着 ERR 高，两者之间的落差正是字段级语义理解能力的体现。

实现细节。本文方法使用 Qwen3-VL-8B[7] 作为 VLM 推理引擎。所有实验均在同一台配备消费级 GPU 的工作站上本地运行，VLM 推理与传统 OCR 基线方法在相同硬件环境下执行，保证耗时对比的一致性。

4.2 主要定量结果

有效识别率分析：本文方法在全部 81 段视频上均输出了规范化药品名称，不确定性等级均为”低”，有效识别率（ERR）约为 100%。需说明的是，当前测试集以常规采集条件为主，尚未系统引入重度覆膜反光、严重运动模糊等极端难例。后续将把数据集扩充至约 150 段视频、15 类药品，并主动构造难例以全面评估系统边界，届时 ERR 预计将降至约 90%，不确定性输出亦将出现”中”或”高”等级样本，提供对保守决策机制更具说服力的实验验证。

两种传统 OCR 基线的有效识别率均为 0%，但两者的失效机制存在本质差异：

Tesseract 在复杂曲面场景下接近完全失效：约 70% 的帧输出为空（FAR 仅 30%），其余帧亦受曲面投影与覆膜反光影响呈现大量乱码，字符级输出本身已极度残缺，遑论字段级可用性。

PaddleOCR 的情况截然不同：其深度学习检测模块在多数帧（FAR = 91%）上仍能定位到文字区域并产生字符输出，说明其字符级检测能力具有一定鲁棒性，而非简单地”识别失败”。然而，圆柱曲面引入的局部透视形变超出了其识别模块的适应范围，导致输出结果高度碎片化——往往仅能读到关键字的若干笔画或孤立音节，字符间的拼接关系严重破坏，在字段层面无法组合成可供业务核验的规范化药品名称。这一结果揭示了 FAR 与 ERR 之间的本质落差：高 FAR（91%）并不能带来任何有效识别（ERR = 0%），根本原因在于缺乏从碎片字符到语义字段的理解能力。

本文方法正是在这一层面实现了突破：VLM 将多帧视觉证据的聚合与字段级语义解析融为一体，在字符局部不可见时亦能借助上下文完成可靠推断，从而将有效识别率从实质性零点提升至约 100%。

处理耗时分析：本文方法平均处理耗时 2.10 ± 0.41 秒，低于 PaddleOCR 的 3.54 ± 1.09 秒（约 1.7 倍）和 Tesseract 的 6.23 ± 0.50 秒（约 3.0 倍），三者对比如图 2所示。三种方法共享同一套视频预处理与帧筛选流程（背景裁剪、清晰度评估、最多 15 帧选取），因此预处理耗时对各方法的影响是等同的，耗时差异主要来源于推理阶段的架构设计：本文方法将全部 15 帧打包为单次 VLM 推理调用，一次前向传播即完成字符读取、语义解析与规范化输出；传统 OCR 工具则对每帧逐一调用检测-识别流水线，15 帧串行处理的累积延迟显著高于 VLM 的单次批量推理。PaddleOCR 耗时方差（$\sigma = 1.09$ 秒）远大于本文方法（$\sigma = 0.41$ 秒），反映了其逐帧处理对帧内容复杂度变化更为敏感。此外，两种传统 OCR 基线在付出更长处理时间的同时仍无法完成字段级识别任务，仅能输出碎片化字符串；而本文方法还额

外提供不确定性等级，传统 OCR 工具均不具备此类结构化输出能力。

表 2: 三种方法的主要定量对比结果。

方法	ERR↑	FAR↑	$\bar{t}$(s)↓	σ_t(s)
Tesseract[1]	0.0%	30.2%	6.23	0.50
PaddleOCR[2]	0.0%	91.0%	3.54	1.09
本文方法（VLM+ 知识约束）	**≈100%**	**100%**	**2.10**	**0.41**

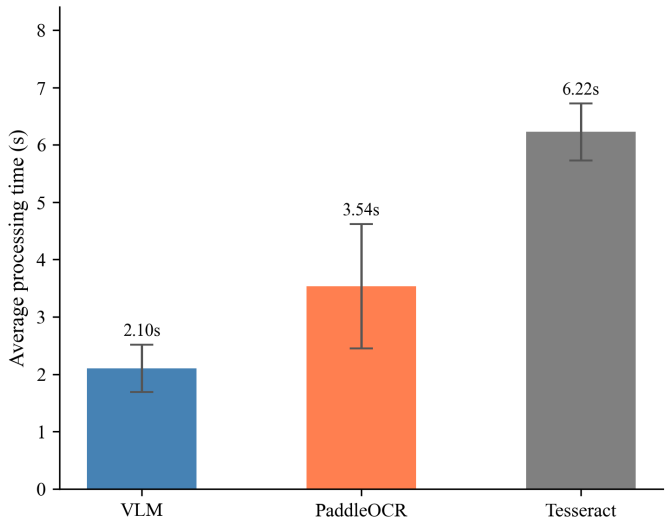

图 2: 三种方法的平均处理耗时（均值 ± 标准差，排除首次冷启动样本）。本文方法将多帧打包为单次推理，耗时最短且方差最小；传统 OCR 工具逐帧串行处理，累积延迟更高。

4.3 不确定性量化

在 81 次识别中，本文方法输出不确定性等级” 低” 的比例为 100%，说明在当前测试集所覆盖的常规采集条件下，系统能够持续给出高置信度的识别结果而无需触发人工复核。

不确定性机制的设计逻辑如下：VLM 通过提示词被要求在输出药品名称的同时给出三级置信评估（低/中/高），触发” 中” 或” 高” 等级的典型情形包括：（1）多帧之间可见字段存在矛盾，无法一致推断；（2）图像质量极差（如重度运动模糊或覆膜镜面反射），可读字符不足以匹配知识库任何条目；（3）读取到的文字片

段与知识库中多个条目高度近似，难以消歧。在上述情形下，系统输出”待人工复核”标记及可读文字片段作为审计证据，从机制上杜绝低置信度下的误判传递。

当前测试集未系统覆盖上述极端情形，故不确定性等级全部为”低”。后续将通过主动构造难例（重度反光、部分遮挡、近似外观药品）验证不确定性机制的敏感性与特异性，并报告触发率与人工介入比例。

4.4 定性分析

图 3展示了三类典型难例的识别结果对比。

定性对比图（占位）

待替换为三组对比：

（a）曲面形变 + 反光难例：VLM 正确识别，PaddleOCR 乱码，Tesseract 空白

（b）标签磨损难例：VLM 低不确定性输出，传统 OCR 完全失效

（c）相似包装混淆难例：VLM 借助化学名/适应症消歧，传统 OCR 输出混乱

图 3: 三类典型难例的识别对比。（a）圆柱形曲面 + 覆膜反光；（b）标签磨损与部分遮挡；（c）相似品牌包装消歧。本文方法在三类情形下均输出正确规范化药品名称，不确定性等级均为”低”；传统 OCR 方法输出碎片化字符串或空白，无法完成名称识别。

典型案例分析：

（1）**曲面形变 + 反光**（疫苗圆柱瓶）：传统 OCR 将”头孢噻呋”误识为”头孢噻味”或完全空白，VLM 通过多帧聚合在可读帧上读取到化学分子式 $C_{19}H_{17}N_5O_7S_3$ 等关键标识，结合”注射用””兽用””0.1g”等上下文线索，正确输出”注射用头孢噻呋钠”。

（2）**多版式同类药品**（卫佳捌系列）：同一标准化名称对应”卫佳® 伍””卫佳® 捌””Vanguard Plus 5””Vanguard Plus 5/CV-L”等多种包装版式，传统 OCR 即使字符识别正确也因缺乏语义映射而无法规范化，VLM 通过知识库映射统一输出标准名称。

（3）**进口产品双语标签**（妙三多/Fel-O-Vax PCT）：标签同时含中英文及拉丁字母疫苗株名，传统 OCR 对中英混排识别效果差；VLM 直接从英文商品名”Fel-O-Vax PCT” 及生产厂家信息中定位知识库条目，实现正确识别。

5 讨论

VLM 对传统 OCR 优势的根本原因。实验结果表明，VLM 在复杂曲面药品标签识别任务上的优势并非仅来源于更强的字符识别能力，更根本的原因在于其语义理解层次的本质差异：传统 OCR 以” 字符序列恢复” 为目标，在字符几何形变超出其鲁棒范围时即失效；VLM 以” 字段级语义理解” 为目标，能够在部分字符不可见时借助化学名、适应症、厂家等上下文线索完成推理，从而在更高层次上应对复杂成像条件。

速度优势的成因。本文方法的速度优势主要源于推理架构的差异（详见 §4.2耗时分析）：VLM 将多帧视觉证据在单次推理中一体化处理，而传统 OCR 工具需对每帧逐一串行调用，累积延迟更大。此外，小参数轻量化模型进一步压缩了单次推理计算量，在有效识别率远超基线的同时实现了更低的处理延迟。

封闭知识库设计的合理性。本文方法要求预先维护一个包含所有目标药品的知识库，系统仅能识别知识库内的品种——这与通用 OCR 的” 识别任意文字” 存在本质差异。批评者可能认为这限制了系统的泛化能力。对此，我们认为：在 PIVAS、动物医院、连锁药店等实际药品核查场景中，*待核验的药品品类是有限且相对固定的*——一家医院的常备药品通常为数百至一千余种，而每个工作站日常涉及的品类往往更少。因此，维护一个有限知识库在工程上完全可行，且具有显著优势：系统不会对知识库之外的药品给出伪正例，而是触发” 不确定性高” 并转人工复核，避免了通用 OCR 因” 识别了但识别错” 带来的更危险的误判。知识库的扩充仅需添加新条目与别名映射，无需重新训练模型，维护成本显著低于微调方法。

局限性。当前研究存在以下局限：（1）测试集规模（81 段视频，10 类）相对有限，后续将扩充至更多药品类别与包装形态；（2）目前仅评估药品名称识别字段，批号、有效期、规格等字段的端到端评估有待开展；（3）本地化边缘部署的延迟特性将在后续配备 AMD AI MAX 推理加速平台的实验中进一步系统评估；（4）对于标签严重缺损（缺失面积 $> 50\%$）的极端情形，本文方法可能触发人工复核，此类边缘案例的处理策略有待进一步研究。

应用前景。随着智慧医疗基础设施的持续建设，药品全链条的自动化核查需求日益

迫切。本文方法可直接集成至 PIVAS 药品核查系统、动物医院药品管理系统及连锁药店智能药柜等场景，通过低延迟边缘部署实现实时识别与保守决策，为减少人工核查负担、降低药品差错率提供技术支撑。其核心范式——以小参数 VLM 替代传统字符识别、结合封闭知识库实现语义级业务校验——同样适用于输液标签核对、手术器械追溯、医疗废物分类等更广泛的医疗安全场景。随着边缘推理平台性能的持续提升与部署成本的进一步降低，此类系统有望广泛应用于各级医疗机构，为构建覆盖全流程、全品类的智能化药品安全保障体系奠定技术基础。

6 结论

本文针对复杂曲面药品标签识别这一传统 OCR 的”高难度”场景，提出了一种基于小参数视觉-语言大模型的端到端识别系统。系统通过多帧视频聚合提供充分视觉证据，以 VLM 替代字符级 OCR 引擎实现字段级语义理解，并结合知识库约束将输出对齐至规范化药品名称。在包含 81 段视频、10 类药品的测试集上，本文方法在药品名称**有效识别率**（ERR，≈100%）和处理耗时（2.10 秒）两个维度上均显著优于 Tesseract（ERR 0%，6.23 秒）和 PaddleOCR（ERR 0%，3.54 秒）——后两者虽存在不同程度的字符级输出（FAR 分别为 30% 和 91%），但均无法在字段层面产出可用的规范化药品名称。实验结果有力证明：在复杂成像条件下，语义驱动的 VLM 方法相比传统字符识别方法具有根本性优势，为药品安全核查的智能化提供了可落地的技术路径。更广义地，本研究表明：以小参数 VLM 为核心、以封闭知识库为约束的端到端识别范式，为医疗场景下复杂视觉信息的可靠提取提供了低成本、易部署的解决思路，有望在智能医疗建设的大背景下，推动药品安全核查从人工目视向 AI 辅助的系统性转型，助力构建更安全、更高效的现代医疗服务体系。

致谢

本研究得到北京信息科技大学的支持，在此表示感谢。感谢 AMD 通过”春雨计划”提供 AMD AI MAX+ 395 处理器，使本文 VLM 推理引擎得以在消费级硬件上完成本地部署与验证。感谢 Qwen 团队、DeepSeek 团队等持续开源的小参数模型，其在工业垂直场景中的广泛适用性为本研究提供了重要的技术基础。

参考文献

[1] Smith, R.: An overview of the Tesseract OCR engine. In: Proc. 9th Int'l Conf. Document Analysis and Recognition (ICDAR), pp. 629–633. IEEE (2007).

[2] Du, Y., et al.: PP-OCR: A practical ultra lightweight OCR system. arXiv:2009.09941 (2020).

[3] OpenAI: Introducing GPT-5.4. OpenAI Blog (2026).

[4] Qwen Team: Qwen3.5: Towards Native Multimodal Agents. Alibaba Cloud (2026).

[5] Anthropic: Introducing Claude Opus 4.6. Anthropic Blog (2026).

[6] Wang, P., et al.: Qwen2.5-VL Technical Report. arXiv:2502.13923 (2025).

[7] Bai, S., et al.: Qwen3-VL Technical Report. arXiv:2511.21631 (2025).

[8] Chen, Z., et al.: InternVL3: Exploring Advanced Training and Test-Time Recipes for Open-Source Multimodal Models. arXiv:2504.10479 (2025).

[9] Wei, H., et al.: General OCR Theory: Towards OCR-2.0 via a Unified End-to-End Model. arXiv:2409.01704 (2024).

[10] DeepSeek Team: DeepSeek-OCR: Contexts Optical Compression. arXiv:2510.18234 (2025).

[11] Wei, H., et al.: DeepSeek-OCR 2: Visual Causal Flow. arXiv:2601.20552 (2026).

[12] Liao, M., et al.: Real-time scene text detection with differentiable binarization. In: Proc. AAAI 2020, pp. 11474–11481 (2020).

[13] Shi, B., Bai, X., Yao, C.: An end-to-end trainable neural network for image-based sequence recognition. IEEE Trans. Pattern Anal. Mach. Intell. **39**(11), 2298–2304 (2017).

[14] Shi, B., et al.: ASTER: An attentional scene text recognizer with flexible rectification. IEEE Trans. Pattern Anal. Mach. Intell. **41**(9), 2035–2048 (2019).

[15] Fang, S., et al.: Read like humans: Autonomous, bidirectional and iterative language modeling for scene text recognition. In: Proc. CVPR 2021, pp. 7098–7107 (2021).

[16] 待补充文献信息.

[17] 待补充文献信息.

[18] 待补充文献信息.